



UNIVERSIDAD POLITÉCNICA DE VICTORIA

REPORTE DE ACTIVIDADES DEL PROYECTO

**DESARROLLO E IMPLEMENTACIÓN DE UN SISTEMA
COTIZADOR EN LÍNEA A TRAVÉS DE INTELIGENCIA
ARTIFICIAL**

QUE PRESENTA

ANGEL GABRIEL CORONADO SÁNCHEZ

**EN CUMPLIMIENTO DE LA ESTADÍA TSU EN
DESARROLLO DE SOFTWARE MULTIPLATAFORMA**

ASESOR INSTITUCIONAL

DR. SAID POLANCO MARTAGÓN

UNIDAD ECONÓMICA RECEPTORA:

TIKS Y CAPACITACIONES S. DE R.L.

ASESOR DE LA UNIDAD ECONÓMICA

DR. MARIO HUMBERTO RODRIGUEZ CHÁVEZ

Ciudad Victoria, Tamaulipas, Agosto de 2026.



Formato de autorización para exposición de Estadía de Técnico Superior Universitario

Fecha y lugar en que se emite: **Ciudad Victoria, Tamaulipas, a 31 de Julio de 2026**

Nombre completo del estudiante: **Angel Gabriel Coronado Sánchez**

Matrícula: **2430124**

Programa Académico: **Ingeniería en Tecnologías de la Información e Innovación Digital**

Por medio del presente, se le informa que tras realizar su Estadía en la empresa **TIKS y Capacitaciones S. DE R.L.** llevando a cabo el proyecto: **Desarrollo e implementación de un sistema cotizador en línea a través de inteligencia artificial**, durante el periodo comprendido **Mayo-Agosto 2026** logrando una ponderación de ____ (60 % posibles) para el criterio de reporte; por lo tanto, se otorga la oportunidad de exponer el trabajo realizado por medio de un informe ejecutivo programado para el día **12** del mes de **Agosto** del año en curso en un horario de **10:00 hrs** en modalidad **Presencial** en la **Oficina I-XXX69**.

Sin otro particular, se le recomienda estar disponible para iniciar su exposición 10 minutos antes de la indicación oficial.

Atentamente

Dr. Said Polanco Martagón
Asesor institucional



Control sumativo de Estadía para Técnico Superior Universitario

Criterio	Valor / Ponderación	Calificación
Reporte	60 %	
Exposición	40 %	
Calificación final		

Datos de la evaluación sumativa

Fecha: **12 / Agosto / 2026**

Dr. Said Polanco Martagón

Asesor institucional

Contenido temático

1	Introducción	1
1.1	Objetivos	1
1.1.1	Objetivo General	1
1.1.2	Objetivos Específicos	1
1.2	Planteamiento del problema	2
1.3	Antecedentes	2
1.3.1	Antecedentes de la empresa	3
1.3.2	Antecedentes teóricos	4
1.4	Tabla comparativa	5
1.5	Justificación	6
1.6	Alcances y Limitaciones	7
1.6.1	Alcances	7
1.6.2	Limitaciones	9
2	Marco Teórico	11
2.1	Inteligencia Artificial y sus aplicaciones en sistemas conversacionales	11
2.1.1	Conceptos generales de IA y sistemas conversacionales	11
2.1.2	Percepción de los usuarios frente a los chatbots	12
2.1.3	Interactividad, humanidad y confianza en chatbots	12
2.1.4	Caso de éxito: Implementación de IA conversacional para optimizar procesos empresariales	12
2.2	Procesamiento de Lenguaje Natural (PLN): ELN y GLN	13
2.2.1	Definición de Procesamiento de Lenguaje Natural	13
2.2.2	Definición de Entendimiento de Lenguaje Natural	14
2.2.3	Definición de Generación de Lenguaje Natural	14
2.3	Alucinaciones en modelos de lenguaje y estrategias de mitigación	15
2.3.1	Definición de alucinaciones en modelos de lenguaje	15
2.3.2	Causas de las alucinaciones en modelos de lenguaje	15
2.3.3	Estrategias de mitigación de alucinaciones	16
2.4	Arquitectura RAG (Retrieval-Augmented Generation) y su aplicación en sistemas conversacionales	16
2.4.1	Definición de RAG	16
2.4.2	Componentes de RAG	17

2.4.3	Ventajas de RAG	17
2.4.4	Aplicación en sistemas conversacionales	18
2.5	Inyección de contexto y system prompting para restricción de respuestas	18
2.5.1	Definición de inyección de contexto	18
2.5.2	Definición de system prompting	18
2.5.3	Diferencias y complementariedad	19
2.5.4	Aplicación en el proyecto	19
2.6	Arquitectura multiempresa (multitenant) en sistemas de software	20
2.6.1	Definición de arquitectura multiempresa	20
2.6.2	Modelos de aislamiento de datos	20
2.6.3	Ventajas de la arquitectura multiempresa	21
2.6.4	Desafíos de la arquitectura multiempresa	22
2.6.5	Aplicación en el proyecto	22
2.7	Caché en sistemas conversacionales	22
2.7.1	Definición de caché	23
2.7.2	Niveles de caché relevantes	23
2.7.3	Beneficios de la caché en sistemas conversacionales	24
2.7.4	Aplicación en el proyecto	25
3	Propuesta de Solución	26
3.1	Descripción general	26
3.2	Arquitectura general	26
3.3	Módulos del sistema	28
3.4	Tecnologías utilizadas	28
3.5	Flujo de trabajo del sistema	29
	Bibliografía	30
	Anexos	33

1. Introducción

En el presente documento se presenta el proyecto **Desarrollo e implementación de un sistema cotizador en línea a través de inteligencia artificial**, un sistema de chat automatizado con inteligencia artificial diseñado para facilitar la cotización de productos a través de distintos canales digitales, así como la gestión administrativa de empresas y clientes. El sistema integra tecnologías de backend, frontend, base de datos e inteligencia artificial, ofreciendo un panel administrativo que consolida la información de múltiples empresas y el historial de cotizaciones generadas.

El objetivo principal del proyecto es reducir el tiempo de atención al cliente en el proceso de cotización de productos, mejorando así la experiencia del usuario final mediante respuestas más rápidas y precisas. Esta propuesta resulta especialmente atractiva para empresas que aún no cuentan con un sistema de chat automatizado y buscan optimizar su servicio al cliente.

A lo largo de este documento se definen todos los procesos e información relevante del proyecto, abordando desde el problema que se pretende resolver, los objetivos establecidos y la justificación de la propuesta, hasta los alcances y limitaciones que delimitan su desarrollo.

1.1. Objetivos

1.1.1. Objetivo General

- **Objetivo:** Desarrollar un sistema cotizador de productos a través de Inteligencia Artificial que automatice el proceso de consulta, análisis y generación de cotizaciones, permitiendo mejorar la rapidez, precisión y atención al usuario, y teniendo como entregable un sistema funcional evaluado.

1.1.2. Objetivos Específicos

- **Objetivo 1:** Analizar los requerimientos funcionales y tecnológicos del sistema, generando como entregable un documento de especificación de requisitos.
- **Objetivo 2:** Diseñar y desarrollar el sistema cotizador con Inteligencia Artificial, generando como entregable un prototipo funcional con sus módulos principales de operación.
- **Objetivo 3:** Validar el desempeño del sistema mediante pruebas de eficiencia, precisión y satisfacción del usuario, generando como entregable un informe de resultados y propuestas

de mejora.

1.2. Planteamiento del problema

El problema que se busca resolver es la ineficiencia en el proceso de cotización de productos en empresas medianas y pequeñas. En la actualidad, dicho proceso se realiza principalmente a través de mensajería instantánea, sin una correcta automatización. Son los propios trabajadores de las empresas quienes atienden manualmente las solicitudes de cotización, lo que genera retardos significativos en el intervalo entre la solicitud del cliente y la respuesta. Esta situación afecta directamente diversos aspectos de la atención al cliente, como la velocidad de respuesta, la disponibilidad fuera del horario laboral y la consistencia de la información proporcionada.

Frente a esta problemática, la presente investigación propone automatizar el proceso de cotización mediante un sistema de respuesta automatizada basado en inteligencia artificial, complementado con un panel administrativo que permita a las empresas revisar y modificar la información relacionada con sus propios productos y las cotizaciones realizadas por los clientes.

Con base en lo anterior, la pregunta de investigación que guía este trabajo es: ¿De qué manera la implementación de un sistema de chat automatizado con inteligencia artificial puede reducir el tiempo de respuesta en el proceso de cotización de productos en empresas de mediano y pequeño tamaño?

1.3. Antecedentes

En los últimos años, el uso de chatbots impulsados por inteligencia artificial ha aumentado en diversos sectores como el comercio electrónico y la atención al cliente. [1] exploraron cómo las señales de humanización y la fiabilidad percibida influyen en la confianza que los usuarios tienen hacia los chatbots de servicio al cliente, identificando que elementos como la naturalidad conversacional, la empatía y la personalización son clave para generar confianza afectiva. De manera similar, [2] demostraron que la interactividad y la percepción de humanidad en los chatbots impactan positivamente en la confianza del usuario, lo que a su vez aumenta el uso de esta tecnología en entornos de comercio electrónico. Ambos estudios coinciden en que la confianza es un factor crítico para la aceptación de chatbots automatizados.

En el ámbito de entornos físicos de venta, [3] desarrollaron un sistema conversacional para supermercados basado en múltiples modelos de lenguaje, capaz de atender tanto consultas básicas o específicas como peticiones más complejas. Su propuesta incluyó un clasificador de

intenciones y un sistema de recuperación de información para ofrecer respuestas personalizadas. Por otro lado, [4] propusieron un framework para tiendas de autoservicio no tripuladas que integra reconocimiento visual de productos con modelos de lenguaje para recomendar artículos basados en las necesidades del cliente, utilizando técnicas de fine-tuning eficientes para adaptar los modelos a datos limitados.

Como se ha visto, aunque estos trabajos han avanzado en la integración de chatbots con IA en contextos comerciales, ninguno aborda completamente un sistema multiempresa que unifique la atención por widget web y WhatsApp, con un panel administrativo centralizado para la gestión de productos, cotizaciones y reportes. El presente proyecto se diferencia al proponer una solución completa que no solo automatiza la atención al cliente en el proceso de cotización mediante IA, sino que también ofrece una herramienta unificada de administración para múltiples negocios, atendiendo una necesidad no cubierta por las investigaciones previas.

1.3.1. Antecedentes de la empresa

TIKS y Capacitaciones S. DE R.L. es una empresa enfocada en brindar servicios de soporte técnico y formación profesional en el área de tecnologías de la información. Su trabajo principal consiste en resolver problemas operativos de hardware y software para empresas y particulares, además de ofrecer cursos prácticos para mejorar el uso de herramientas digitales.

Su misión es impulsar la productividad de sus clientes mediante el dominio de la tecnología, buscando siempre que las personas y negocios sean más eficientes al utilizar herramientas digitales. Para lograr esto, se enfocan en cerrar la brecha técnica a través de la capacitación continua y la certificación oficial de competencias.

En cuanto a sus actividades, la empresa combina el mantenimiento técnico con la enseñanza. Por un lado, se encargan de reparar equipos, optimizar sistemas y proteger la infraestructura informática de sus clientes. Por otro lado, operan como un centro de capacitación y certificación donde enseñan a manejar programas de oficina y diseño, validando profesionalmente los conocimientos adquiridos por sus alumnos.

Actualmente me encuentro trabajando en uno de sus proyectos que consiste en el **Desarrollo e implementación de un sistema cotizador en línea a través de inteligencia artificial**, siendo esta una de las soluciones tecnológicas que ofrecen a distintas empresas y/o negocios.

1.3.2. Antecedentes teóricos

Inteligencia Artificial y Procesamiento de Lenguaje Natural La inteligencia artificial (IA) es una rama de la computación que busca desarrollar sistemas capaces de realizar tareas que normalmente requieren inteligencia humana, como el razonamiento, el aprendizaje y la comprensión del lenguaje [5]. Dentro de la IA, el Procesamiento de Lenguaje Natural (NLP, por sus siglas en inglés) se enfoca en la interacción entre computadoras y lenguaje humano, permitiendo a las máquinas interpretar, procesar y generar texto de manera autónoma [6].

En los últimos años, los modelos de lenguaje de gran tamaño (LLMs), basados en arquitecturas Transformer [7], han revolucionado el campo al demostrar capacidades avanzadas en tareas de conversación y generación de texto [8]. Modelos como GPT-4o-mini, utilizado en el presente proyecto, ofrecen un equilibrio entre rendimiento y costo computacional, siendo ideales para aplicaciones conversacionales en entornos comerciales. Estos modelos, sin embargo, son propensos a generar información no veraz (conocida como alucinaciones) si no se les restringe adecuadamente mediante fuentes de información confiables.

Arquitectura RAG (Retrieval-Augmented Generation) La arquitectura RAG (Retrieval-Augmented Generation) fue propuesta por [9] como un enfoque para mejorar la precisión y relevancia de las respuestas generadas por modelos de lenguaje. RAG combina un sistema de recuperación de información con un modelo generativo: ante una consulta del usuario, se recuperan documentos o datos relevantes desde una fuente externa (como una base de datos), y estos se inyectan como contexto adicional en el prompt del modelo generativo [10].

Este enfoque reduce las alucinaciones del modelo, ya que las respuestas se basan en información recuperada en lugar de depender exclusivamente del conocimiento interno del modelo. En el presente proyecto, la arquitectura RAG se implementa para que el chatbot consulte la base de datos PostgreSQL de productos de cada empresa y genere respuestas basadas exclusivamente en el catálogo real disponible.

Integración con WhatsApp Business Platform WhatsApp Business Platform es la solución oficial de Meta para que empresas puedan integrar servicios de mensajería automatizada a través de WhatsApp. A diferencia de la aplicación WhatsApp Business convencional, la plataforma está diseñada para entornos de alto volumen y permite la automatización mediante APIs, webhooks y mensajes plantilla [11].

Los webhooks permiten que el sistema reciba notificaciones en tiempo real cuando un cliente envía un mensaje. Las APIs REST facilitan el envío de respuestas automáticas. Adicionalmente, la plataforma impone políticas de uso, como la ventana de 24 horas para respuestas gratuitas y el uso de mensajes plantilla para comunicaciones iniciadas por la empresa fuera de dicho período [11]. En este proyecto, la integración con WhatsApp Business Platform permite que el chatbot atienda solicitudes de cotización a través de este canal, registrando cada conversación en la base de datos y manteniendo la relación entre cada número de WhatsApp y la empresa correspondiente.

1.4. Tabla comparativa

Con el fin de evidenciar las mejoras que introduce el presente proyecto, en la Tabla 1 se contrastan los procesos realizados de manera tradicional (sin automatización) frente a la operación del sistema propuesto, abarcando aspectos como el tiempo de respuesta, disponibilidad, registro de conversaciones y gestión de productos.

Tabla 1: Comparativa entre el proceso tradicional y el sistema propuesto

Aspecto	Antes (sin el sistema)	Después (con el sistema)
Proceso de cotización	Realizado manualmente por empleados vía WhatsApp o llamada telefónica	Proceso automatizado mediante chatbot con IA vía WhatsApp/widget
Tiempo de respuesta al cliente	Varía desde minutos hasta horas	Inmediato o en algunos segundos
Disponibilidad del servicio	Únicamente en horario laboral	Disponible las 24 horas de los 7 días de la semana
Registro de conversaciones	Nulo o bastante informal (capturas de pantalla)	Registro centralizado en base de datos
Cotizaciones generadas	Manualmente, propensas a tener errores de cálculo	Automáticamente, con cálculos precisos
Almacenamiento de cotizaciones	A papel, en archivos sueltos o mensajes de WhatsApp	En base de datos, con posibilidad de consultar y exportar a PDF
Gestión de productos	En Excel o a papel	Panel administrativo con CRUD
Disponibilidad de información	Distintas maneras de manejar la distinta información	Panel centralizado con la información necesaria

1.5. Justificación

El presente proyecto se justifica desde distintas perspectivas por los beneficios que puede aportar al automatizar el proceso de cotización de productos en empresas medianas y pequeñas.

Desde el punto de vista tecnológico, el proyecto representa la integración de una tecnología emergente como lo es la inteligencia artificial en un sector productivo como lo son las empresas o negocios. La integración de un chatbot basado en IA se encarga de modernizar los canales de atención al cliente, ofreciendo un servicio más rápido y eficiente.

Desde el punto de vista económico, la automatización del proceso de cotización reduce los intervalos de tiempo entre la solicitud del cliente y la respuesta, lo que puede traducirse en una optimización de los empleados de la empresa, liberándolos de tareas repetitivas.

Desde el punto de vista práctico, el sistema genera un reporte que integra los productos cotizados y la información necesaria sobre estos, además de almacenar toda la información sobre los productos de cierto negocio, facilitando el seguimiento de las cotizaciones realizadas y la disponibilidad de los productos.

Debido a lo anterior, invertir tiempo y recursos en este proyecto vale la pena porque ofrece una solución concreta a una situación real que enfrentan empresas o negocios en la actualidad.

1.6. Alcances y Limitaciones

1.6.1. Alcances

Sobre el sistema en general

- El sistema consistirá en un chatbot con inteligencia artificial para atención al cliente, consulta de productos y generación automática de cotizaciones.
- La plataforma será multiempresa, permitiendo que múltiples negocios operen de manera independiente dentro del mismo sistema.
- El sistema incluirá un panel administrativo web para la gestión de empresas, usuarios, productos, conversaciones y reportes.

Sobre los canales de comunicación

- El chatbot estará disponible a través de un widget web embebible en los sitios de las empresas.
- El chatbot estará disponible a través del WhatsApp de cada empresa.
- Ambos canales de comunicación (WhatsApp y widget web) compartirán el mismo motor de IA y registrarán las conversaciones en la base de datos.

Sobre los perfiles de usuario

- El sistema contará con tres perfiles internos: administrador general, administrador de empresa y usuario de empresa.

- Los clientes finales interactuarán únicamente a través del widget web o WhatsApp, sin acceso al panel administrativo.
- El administrador general tendrá visibilidad y control sobre todas las empresas del sistema.
- El administrador de empresa podrá gestionar únicamente su propia empresa, sus productos y sus usuarios.
- El usuario de empresa podrá gestionar productos y visualizar reportes, con permisos restringidos.

Sobre la gestión de productos

- El sistema permitirá el registro manual de productos mediante formulario.
- El sistema permitirá la importación masiva de productos mediante archivos CSV.
- El sistema permitirá la importación asistida con IA para archivos sin formato predefinido.
- Se podrán editar, activar, desactivar o eliminar productos.
- Se podrán gestionar categorías, precios, descripciones, imágenes, stock y unidad de medida.

Sobre las conversaciones y cotizaciones

- El chatbot responderá exclusivamente con base en el catálogo de productos real de cada empresa.
- El sistema generará cotizaciones automáticas a partir de los productos seleccionados por el cliente durante la conversación.
- Las cotizaciones incluirán cálculo de cantidades, precios, subtotales y totales.
- Las cotizaciones podrán ser guardadas, consultadas en el historial y exportadas a PDF.
- Se registrará el historial completo de mensajes de cada conversación.

Sobre los reportes y auditoría

- El sistema generará reportes de uso por empresa: tokens consumidos, conversaciones atendidas, productos consultados y cotizaciones generadas.
- Los reportes podrán filtrarse por rango de fechas.
- Los reportes podrán exportarse a Excel y PDF.
- Se registrarán logs de auditoría incluyendo fecha, hora, usuario o empresa asociada, y resultado de la acción.

Sobre el widget web

- Se generará un script embebible por empresa para integrar el widget en sitios web externos.
- El widget permitirá configuración visual personalizada: color principal, logo, nombre del asistente, mensaje inicial, posición en pantalla, estilo de burbuja, mensajes de error y carga.
- Se implementará protección contra abuso o llamadas excesivas al widget.

Fronteras

- No se incluyen otros canales de comunicación como Messenger, Telegram, SMS o correo electrónico.
- No se soportan imágenes, videos, audios ni documentos en el chat, únicamente texto.
- No se contempla app móvil, el acceso es vía web para el panel administrativo y vía widget/WhatsApp para el chatbot.
- El sistema únicamente operará en español, no se contemplan otros idiomas.

1.6.2. Limitaciones

- El desarrollo del sistema debe completarse dentro del período establecido por el calendario académico (Mayo-Agosto 2026), lo que puede restringir la profundidad de ciertos módulos o la implementación de funcionalidades adicionales no críticas.
- La calidad de las respuestas del chatbot depende de la calidad y completitud del catálogo de productos ingresado por cada empresa. Datos incompletos o inconsistentes pueden

afectar el rendimiento de la IA.

- El despliegue inicial contempla un solo Droplet de Digital Ocean, lo que podría limitar la capacidad de respuesta ante picos de demanda superiores a los 200 conversaciones simultáneas estimadas como base.

2. Marco Teórico

En esta sección se presentan los conceptos teóricos y antecedentes relacionados con el tema de investigación. Se abordarán los fundamentos teóricos que sustentan el estudio, así como las investigaciones previas que han contribuido al desarrollo del conocimiento en esta área.

2.1. Inteligencia Artificial y sus aplicaciones en sistemas conversacionales

En esta sección, se define la Inteligencia Artificial (IA) y lo que es un sistema conversacional basado en IA; además, se revisan estudios encargados de analizar diversos aspectos de estos sistemas, como la percepción de los usuarios hacia estos. Por último, se revisa el caso de éxito de una empresa que ha integrado un sistema conversacional basado en IA y los beneficios que les ha aportado.

2.1.1. Conceptos generales de IA y sistemas conversacionales

Se define a la Inteligencia Artificial (IA) como el campo de estudio enfocado en el desarrollo de tecnología capaz de realizar tareas que requieren inteligencia humana. Los sistemas basados en IA están diseñados para imitar la capacidad de aprendizaje y razonamiento que poseen los seres humanos [12].

La IA se utiliza en diversas áreas del conocimiento, como la robótica, los vehículos autónomos y el reconocimiento facial y de objetos. No obstante, en esta sección se abordarán sus aplicaciones en sistemas conversacionales, tales como asistentes virtuales y chatbots.

Una IA generativa de texto es un tipo de Inteligencia Artificial que puede generar texto a partir de datos existentes, y se encuentra en rápido desarrollo con un amplio potencial de aplicaciones [12]. Ejemplos de ello son GPT, desarrollada por OpenAI, y LLaMa, desarrollada por Meta, ambas ampliamente utilizadas en sistemas conversacionales.

En estos sistemas, uno de los principales desafíos es garantizar la coherencia y veracidad de las respuestas, lo que ha dado lugar al estudio de fenómenos como las alucinaciones en modelos de lenguaje, tema que se abordará en la Sección 2.3.

2.1.2. Percepción de los usuarios frente a los chatbots

Por otro lado, Fondevila-Gascón et al. [13] realizaron un estudio empírico en España para conocer la percepción de los clientes sobre los chatbots como agentes de atención al cliente. Los resultados muestran que la percepción del usuario depende del contexto. Si la pregunta o solicitud es sencilla, la percepción es positiva; si es compleja, es negativa. También se observa que los factores principales que afectan la percepción son la calidad y el contexto.

Además, se concluye que existe una relación entre la calidad del chatbot y la satisfacción del cliente, y se identifica que el factor más importante para el usuario al interactuar con un chatbot es la efectividad. Los autores también señalan que los usuarios prefieren interactuar con agentes humanos en situaciones complejas, como quejas o reclamaciones.

2.1.3. Interactividad, humanidad y confianza en chatbots

Por su parte, Ding y Najaf [2] investigaron el impacto de la interactividad y la percepción de humanidad en la confianza hacia los chatbots en el comercio electrónico. Los autores encontraron que tanto la interactividad como la humanidad percibida tienen un efecto positivo en la confianza del usuario.

También identificaron que la confianza actúa como un mediador entre estos factores y la intención de adoptar chatbots. Además, el estudio mostró que el disfrute percibido modera la relación entre la confianza y la intención de adopción, es decir, cuando el usuario disfruta la interacción, la confianza tiene un mayor impacto en su decisión de usar el chatbot. Estos hallazgos resaltan la importancia de diseñar chatbots que no solo sean interactivos y humanos, sino también agradables para el usuario.

2.1.4. Caso de éxito: Implementación de IA conversacional para optimizar procesos empresariales

A modo de muestra de los beneficios que puede traer la implementación de una IA conversacional a los diversos procesos que existen dentro de una empresa, se analiza el caso de la empresa OHLA [14], grupo líder en el sector de la Ingeniería Civil y Construcción en España.

Tras una exploración corporativa, se reveló la necesidad y viabilidad de un sistema de IA generativa, más específicamente uno que sirviera al propósito de mejorar los procesos y decisiones en áreas críticas de la organización [14].

La solución implementada se centró en el desarrollo de un asistente virtual, se utiliza la IA para optimizar procesos, mejorar la eficiencia operativa y proporcionar a los empleados de OHLA un acceso fácil y rápido a información relevante con respuestas precisas a través de interacciones conversacionales con un chatbot potenciado por Azure Open IA. Otras funcionalidades a destacar son la indexación y búsqueda de información en diversas fuentes de datos, la traducción de contenido y una sección de preguntas frecuentes para cada departamento, ofreciendo así una experiencia personalizada para los usuarios [14].

Los beneficios reportados tras la implementación de la solución tecnológica incluyen una eficiencia operativa mejorada con el acceso instantáneo a información relevante, reduciendo el tiempo de búsqueda de información, además de impulsar la capacidad de los empleados para innovar y adaptarse a los cambios en el entorno [14].

2.2. Procesamiento de Lenguaje Natural (PLN): ELN y GLN

En esta sección, se define el Procesamiento de Lenguaje Natural (PLN), así como dos de sus subdisciplinas fundamentales para sistemas conversacionales: el Entendimiento de Lenguaje Natural (ELN) y la Generación de Lenguaje Natural (GLN). Se explica brevemente cada uno de estos conceptos y su relevancia en el desarrollo del presente proyecto.

2.2.1. Definición de Procesamiento de Lenguaje Natural

Según la definición de Muñoz Guillena [15], el procesamiento de lenguaje natural (PLN) es una rama de la inteligencia artificial centrada en la capacidad de las máquinas para comprender, interpretar y generar lenguaje humano.

A palabras generales, un sistema de PLN es la emulación por computadora de la capacidad humana para generar e interpretar textos. El sistema genera o interpreta texto justamente como lo haría un ser humano [15].

El gran beneficio del PLN es que permite que las máquinas puedan aprender sin necesidad de programación explícita, esto mediante el análisis de patrones lingüísticos y semánticos, pudiendo identificar relaciones y conceptos abstractos, y generando nuevo conocimiento a partir de esto [15].

El PLN se compone de dos subdisciplinas fundamentales: el Entendimiento de Lenguaje Natural (ELN) y la Generación de Lenguaje Natural (GLN). El ELN se centra en la comprensión del

significado detrás del lenguaje humano, mientras que el GLN se enfoca en la creación de texto en lenguaje humano.



Figura 1: Relación entre el Procesamiento de Lenguaje Natural y sus subdisciplinas.

2.2.2. Definición de Entendimiento de Lenguaje Natural

El Entendimiento del Lenguaje Natural (ELN) es una subdisciplina del PLN centrada en la capacidad de las máquinas para comprender el significado y la intención tras el lenguaje humano. Va más allá de un procesamiento superficial del texto para poder interpretar el contexto, propósito y las inferencias que los humanos hacen al comunicarse [15]. Incluye tareas como el análisis semántico, desambiguación de palabras e inferencia lógica [15].

En sistemas conversacionales como el propuesto en este documento, el ELN es un proceso fundamental que permitirá interpretar las consultas del usuario.

2.2.3. Definición de Generación de Lenguaje Natural

La Generación de Lenguaje Natural (GLN) es una subdisciplina del PLN encargada de la creación de texto en lenguaje humano a partir de datos estructurados o no estructurados. Su objetivo es producir texto que cumpla con ciertas características: coherencia, fluidez y adecuación al contexto [15]. Puede aplicarse en la generación de informes, los sistemas conversacionales y la producción de contenido [15].

En sistemas conversacionales como el propuesto en este documento, el GLN es un proceso esencial que se encargará de generar respuestas coherentes y personalizadas a partir de la información recuperada de la base de datos.

2.3. Alucinaciones en modelos de lenguaje y estrategias de mitigación

En esta sección, se define el concepto de alucinación en modelos de lenguaje, se describen las principales causas que las originan y se mencionan brevemente algunas estrategias para mitigarlas, las cuales serán desarrolladas con mayor profundidad en secciones posteriores.

2.3.1. Definición de alucinaciones en modelos de lenguaje

El término "alucinación" se utiliza como metáfora para denominar al contenido generado por una IA que carece de sentido o no es fiel al contenido fuente que le fue proporcionado [16]. Debe tenerse claro que este término se utiliza como metáfora antropomórfica para describir lo que es un mero error de procesamiento y la obtención de resultados indeseados en un sistema informático [16].

2.3.2. Causas de las alucinaciones en modelos de lenguaje

Las alucinaciones generadas por un modelo de Inteligencia Artificial (IA) pueden ser atribuidas a distintos motivos [16]. Existen diversas adversidades que pueden influir a esto, tales como la complejidad del lenguaje humano, calidad deficiente de los datos de entrada, sesgo en los conjuntos de datos de entrenamiento y el diseño limitado de los datos [16].

Como ya se mencionó, se definen distintas causas, a continuación se definen las principales:

- **Sobre-optimización:** Tomando el ejemplo de modelos como GPT-3, los cuales fueron optimizados para producir texto coherente y contextualmente relevante [16]. Esto los llevó a inventar información ajustada al contexto, incluso si no es verídica.
- **Ausencia de verificación externa:** Hay posibilidad de que ocurra si el modelo carece de la capacidad de verificar la información en fuentes externas como internet [16].
- **Inferencia contextual:** El hecho de que los modelos de lenguaje inferen el contexto a partir del texto precedente provoca que puedan interpretarlo incorrectamente, lo que llevaría a alucinaciones [16].

2.3.3. Estrategias de mitigación de alucinaciones

Dado el riesgo que representan las alucinaciones en sistemas conversacionales, se han desarrollado diversas estrategias para mitigar su aparición. Estas estrategias buscan limitar la libertad del modelo para inventar información y asegurar que sus respuestas estén fundamentadas en fuentes confiables.

Una de las estrategias más efectivas es la arquitectura RAG (Retrieval-Augmented Generation). Este enfoque, que se abordará con mayor detalle en la Sección 2.4, consiste en que el modelo consulte una fuente de información externa antes de generar una respuesta, basando su respuesta únicamente en el contenido recuperado [17, 18]. Esto reduce las alucinaciones al anclar las respuestas en datos verificables.

Otra estrategia clave, que también se desarrollará más adelante en la Sección 2.5, es el *system prompting*. Esta técnica consiste en definir instrucciones claras y estrictas para el modelo desde el inicio de la conversación, restringiendo su comportamiento y evitando que invente información [19]. Adicionalmente, el ajuste del parámetro de temperatura permite controlar la creatividad de las respuestas: un valor bajo (cercano a 0) hace que el modelo sea más determinista y menos propenso a generar información no verídica [20].

2.4. Arquitectura RAG (Retrieval-Augmented Generation) y su aplicación en sistemas conversacionales

En esta sección, se define la arquitectura RAG, se describen sus componentes principales y se explican las ventajas de su implementación. Finalmente, se menciona su aplicación en el presente proyecto.

2.4.1. Definición de RAG

RAG (Retrieval-Augmented Generation) es una técnica de inteligencia artificial dentro del campo del procesamiento de lenguaje natural que combina la recuperación de información con la generación de texto a partir de modelos de lenguaje. Su funcionamiento se basa en el uso de documentos relevantes recuperados para proporcionar contexto adicional, lo que permite generar respuestas más precisas y detalladas, especialmente útil en aplicaciones donde se requiere obtener información exacta y completa [21].

En la figura 2 se ilustra el funcionamiento básico de la arquitectura RAG, mostrando como se

necesita de una base de conocimiento y adición de contexto relevante para obtener una respuesta precisa.




Figura 2: Funcionamiento básico de la arquitectura RAG.

2.4.2. Componentes de RAG

Un sistema RAG se compone de dos fases principales: la recuperación de información y la generación de la respuesta.

En la fase de recuperación, la consulta del usuario se utiliza para realizar una búsqueda en una base de datos indexada o en fuentes externas. Para esto se emplean técnicas como la búsqueda semántica o la coincidencia de palabras clave, que permiten encontrar la información más relevante para la consulta. La información recuperada se convierte en vectores que se almacenan en una base de datos vectorial, facilitando la búsqueda eficiente de similitudes [21]. Los documentos con las puntuaciones más altas se seleccionan para su posterior procesamiento.

En la fase de generación, la información recuperada se procesa para ayudar a generar una respuesta. Un modelo de lenguaje basado en deep learning, como un LLM, utiliza la información recuperada para generar las respuestas de texto. Estas respuestas suelen ser más precisas y contextuales, ya que han sido moldeadas por la información de recuperación [21].

2.4.3. Ventajas de RAG

RAG presenta ventajas sobre los modelos de lenguaje que funcionan de forma aislada. Permite que los modelos accedan a fuentes de datos externas más recientes y actualizadas de forma eficiente, ya que no es necesario reentrenar el modelo para mejorar la precisión o la relevancia en las respuestas [21].

Además, RAG ayuda a reducir el problema de las alucinaciones en los modelos de lenguaje. Al contar con un paso previo de recuperación de información, el modelo no depende solamente de lo que hay en la base de datos que se ha utilizado para entrenarlo, sino que también cuenta con los documentos indexados de forma externa, ofreciendo una información añadida que permite generar una respuesta más completa y precisa [21].

2.4.4. Aplicación en sistemas conversacionales

En el contexto de un sistema conversacional como el propuesto en este proyecto, la arquitectura RAG juega un papel fundamental. El chatbot necesita responder preguntas sobre productos y generar cotizaciones basadas en el catálogo real de cada empresa. Sin RAG, el modelo de lenguaje podría inventar productos o precios que no existen en la base de datos.

Básicamente, RAG permite que el chatbot consulte la base de datos de productos y precios antes de generar una respuesta. Esto asegura que las respuestas sean precisas y estén basadas en información verificada, reduciendo significativamente el riesgo de alucinaciones y mejorando la experiencia del usuario.

2.5. Inyección de contexto y system prompting para restricción de respuestas

En esta sección, se definen los conceptos de inyección de contexto y system prompting, se explica cómo se complementan y se menciona su aplicación en el presente proyecto.

2.5.1. Definición de inyección de contexto

La inyección de contexto consiste en añadir información relevante y específica al prompt de un modelo de lenguaje antes de que este genere una respuesta. El objetivo es proporcionar al modelo el conocimiento necesario para responder de manera precisa y fundamentada, reduciendo así la dependencia de su memoria interna y mitigando el riesgo de alucinaciones [22]. Esta técnica es especialmente útil en aplicaciones donde se requiere información actualizada o de dominio específico [22].

2.5.2. Definición de system prompting

El system prompting se refiere al uso de directrices predefinidas que se colocan al inicio de la conversación para guiar el comportamiento del modelo. Estas instrucciones tienen prioridad

sobre las indicaciones del usuario y se utilizan para establecer reglas, definir roles y restringir el comportamiento del modelo a lo largo de toda la interacción [19]. Los system prompts permiten que el modelo mantenga una conducta consistente, como aplicar guardrails o ceñirse a un tema específico [19].

En la figura 3 se ilustra el como se complementan el system prompt y el user prompt, siendo el primero aquel que establece las reglas y el comportamiento de la IA mientras que el segundo es la instrucción enviada por el usuario.




Figura 3: Diagrama de componentes del system prompting.

2.5.3. Diferencias y complementariedad

Ambos conceptos se complementan en el diseño de sistemas conversacionales. El system prompting establece las reglas generales de comportamiento, definiendo el rol del asistente y las restricciones que debe cumplir en todas las interacciones [19]. La inyección de contexto, por su parte, proporciona la información específica y actualizada que el modelo necesita para responder a una consulta particular [22]. Mientras que el system prompt define cómo debe comportarse el modelo, la inyección de contexto le proporciona el conocimiento para hacerlo correctamente.

2.5.4. Aplicación en el proyecto

En el presente proyecto, el system prompting se utiliza para definir el rol del chatbot como un asistente de ventas. A través de instrucciones iniciales, se le indica al modelo que debe responder únicamente con base en la información proporcionada, que no debe inventar productos y que debe limitarse a las reglas de negocio definidas.

La inyección de contexto se implementa mediante la arquitectura RAG descrita en la sección anterior. Antes de generar una respuesta, el sistema consulta la base de datos PostgreSQL para recuperar la información real de los productos solicitados y la inyecta en el prompt. De esta

forma, el modelo genera respuestas precisas y verificables, reduciendo significativamente el riesgo de alucinaciones.

2.6. Arquitectura multiempresa (multitenant) en sistemas de software

En esta sección, se define la arquitectura multiempresa (multitenant), se describen los modelos de aislamiento de datos, se mencionan sus ventajas y desafíos, y se explica su aplicación en el presente proyecto.

2.6.1. Definición de arquitectura multiempresa

La arquitectura multiempresa, también conocida como multitenant, es el enfoque de diseño de software en el cual una única instancia de una aplicación sirve a varios clientes o inquilinos (tenants) [23].

Se define como inquilino a un usuario individual o a un grupo de usuarios, como una empresa, dentro de la cual comparten acceso y privilegios dentro de la instancia de la aplicación [23].

Lo que hace que esta arquitectura sea utilizada es que asegura que los datos de cada inquilino están aislados y son invisibles para otros inquilinos con los que se comparte instancia de aplicación, esto garantiza la seguridad y privacidad de los datos de los inquilinos [23].

En la figura 4 se muestra la diferencia entre la arquitectura single-tenant y multi-tenant, donde se puede observar que en la primera cada inquilino tiene su propia instancia de aplicación y base de datos, mientras que en la segunda todos los inquilinos comparten la misma instancia de aplicación y base de datos, pero con un aislamiento lógico de los datos.

2.6.2. Modelos de aislamiento de datos

Ha sido mencionada la importancia de mantener los datos de cada inquilino aislados y seguros. Para ello existen distintos enfoques para el aislamiento de datos según diversos factores. A continuación se listan los tres modelos más comunes:

- **Esquema compartido con ID de inquilino:** Todos los inquilinos comparten la misma base de datos y esquema, cada registro de datos se identifica mediante un ID de inquilino. Es el modelo más eficiente en cuanto a uso de recursos, sin embargo requiere un estricto uso de consultas y controles de acceso [24].




Figura 4: Arquitectura single-tenant en comparación con arquitectura multi-tenant.

- **Esquema independiente por inquilino:** Cada inquilino tiene un esquema propio dentro de una misma base de datos, esto permite mayor flexibilidad en la estructura de datos y una separación lógica más sencilla. En comparación al modelo anterior este mejora la seguridad pero añade complejidad a la gestión [24].
- **Base de datos independiente por inquilino:** Cada inquilino accede a una base de datos completamente aislada, esto ofrece el máximo nivel de seguridad de datos en esta arquitectura. En comparación a los modelos anteriores permite una estricta protección de los datos aunque a costa de un mayor uso de infraestructura [24].

2.6.3. Ventajas de la arquitectura multiempresa

- **Costos más bajos:** Los costos tienden a ser más bajos debido a que se puede servir múltiples inquilinos desde una sola aplicación, además de que estos comparten infraestructura y centro de almacenamiento de datos [23, 24].
- **Escalabilidad:** Una única instancia de aplicación puede hacer que se pueda recibir a más inquilinos sin necesidad de una gran reconfiguración [24].
- **Mantenimiento continuo:** Los cambios que se hagan, las características o arreglos que se agreguen se realizan una sola vez debido a que existe una única instancia de aplicación [23, 24].

- **Eficiencia:** Los recursos compartidos y gestión centralizada se traduce en menos sistemas aislados y un mayor aprovechamiento de las capacidades de procesamiento y almacenamiento [24].

2.6.4. Desafíos de la arquitectura multiempresa

- **Fuga de datos:** Como ya se mencionó, la seguridad y privacidad de los datos de cada inquilino es fundamental, si el aislamiento de datos no se implementa de manera correcta, existe el riesgo de acceso no autorizado o fuga de datos entre los inquilinos [24].
- **Contención de recursos:** El uso intensivo por parte de un inquilino puede degradar el rendimiento y la experiencia de los demás, esto debido a que comparten la misma infraestructura. Para ello, se requiere una cuidadosa asignación de recursos y monitorización [24].
- **Personalización limitada:** El hecho de compartir infraestructura y lógica puede dificultar o limitar directamente un amplio espectro de opciones de personalización [24].
- **Complejidad en el control de acceso:** Esta arquitectura requiere un desarrollo adicional para poder gestionar correctamente la identificación de los usuarios, la administración de permisos y la segregación de datos [24].

2.6.5. Aplicación en el proyecto

Actualmente, en el proyecto desarrollado se trabaja con el modelo de "Esquema compartido con ID de inquilino", esto debido a la facilidad de implementación que ofrece este modelo de separación de datos. Aunque proporciona un menor nivel de aislamiento que los modelos anteriores, se trabaja arduamente en asegurar la seguridad y protección de los datos de cada inquilino. Cada tabla que almacena datos correspondientes a una empresa, como `products`, `conversations` o `quotations`, incluye un campo llamado `company_id` que los relaciona con la empresa a la que pertenecen. Además, todas las consultas a la base de datos se filtran según el rol del usuario y la empresa a la que pertenece, lo que asegura que los datos permanezcan aislados y seguros.

2.7. Caché en sistemas conversacionales

En esta sección, se define el concepto de caché, se describen los tipos más comunes, se explican sus beneficios en sistemas conversacionales y se menciona su aplicación en el presente proyecto.

2.7.1. Definición de caché

La memoria caché es un tipo de almacenamiento de datos que es utilizado para guardar información a la que se accede frecuentemente, esto con el objetivo de obtener un tiempo de respuesta más rápido. [25]

En la memoria caché se almacenan datos e instrucciones que se necesitarán para completar distintas tareas a corto plazo, accediendo a estos a una mayor velocidad que si se buscasen en la memoria RAM. [25]

Existen dos escenarios en la búsqueda de datos en la memoria caché: un *cache hit* ocurre cuando los datos solicitados se encuentran en la memoria caché, lo que permite un acceso rápido y eficiente. Por otro lado, un *cache miss* ocurre cuando los datos solicitados no están presentes en la memoria caché, lo que obliga al sistema a buscar los datos en la memoria RAM, resultando en un tiempo de respuesta más lento. [25]

En la figura 5 se ilustra el funcionamiento básico de la memoria caché, mostrando los escenarios de *cache hit* y *cache miss*, dejando claro como el caché complementa a la base de datos.




Figura 5: Funcionamiento básico de caché: Cache hit y Cache miss.

2.7.2. Niveles de caché relevantes

- **Caché de base de datos:** Tomando como ejemplo PostgreSQL, este tipo de caché se sitúa en la capa de persistencia de datos, permitiendo almacenar en memoria RAM los datos y las consultas que se utilizan con mayor frecuencia. Utiliza una memoria interna

propia del gestor de base de datos y aprovecha la memoria del sistema operativo. Reserva espacios adicionales para operaciones complejas como ordenamiento y combinación de tablas, mejorando así el rendimiento del acceso a datos persistentes. [26]

- **Caché de aplicación:** Tomando como ejemplo Redis, este tipo de caché se sitúa en la capa de aplicación, permitiendo almacenar respuestas generadas y resultados procesados que se reutilizan frecuentemente. Utiliza estructuras de datos optimizadas en memoria para acceso ultra rápido. Es especialmente útil para gestionar sesiones de usuario, cachear respuestas de servidor y mantener datos temporales que no requieren persistencia inmediata en base de datos. [27]

Básicamente, las diferencias principales entre estos dos tipos son el nivel arquitectónico en el que operan: la caché de base de datos optimiza el acceso a datos persistentes a nivel del gestor, mientras que la caché de aplicación optimiza respuestas y cálculos complejos a nivel de la lógica de negocio.

2.7.3. Beneficios de la caché en sistemas conversacionales

La implementación de estrategias de caché en sistemas conversacionales aporta beneficios que impactan directamente en el rendimiento, los costos y la experiencia del usuario.

- **Mejora de rendimiento:** La caché permite reducir la latencia en las respuestas, disminuyendo los tiempos de procesamiento y la carga en el servidor. Esto se traduce en aplicaciones más rápidas y receptivas, capaces de manejar grandes volúmenes de información sin afectar el rendimiento. [28]
- **Menor tiempo de respuesta:** Una vez que los resultados de las consultas están almacenados en caché, las respuestas llegan de 2 a 3 veces más rápido, lo que permite reducir significativamente el tiempo que el usuario espera por una respuesta. [28]
- **Mejor experiencia de usuario:** Tiempos de respuesta más rápidos crean conversaciones más naturales y fluidas. Los usuarios perciben los sistemas de IA que responden rápido como más inteligentes y útiles, lo que aumenta la satisfacción, el engagement y la retención de usuarios. [28]

2.7.4. Aplicación en el proyecto

En el presente proyecto, el uso de caché se implementa mediante Redis para almacenar los resultados de consultas frecuentes a la base de datos. Esto incluye, por ejemplo, la lista de productos de una empresa, la configuración del widget y los parámetros generales del sistema. Almacenar esta información en caché permite que el chatbot no tenga que consultar PostgreSQL en cada interacción, reduciendo así los tiempos de respuesta y la carga sobre la base de datos. Adicionalmente, la caché contribuye a una experiencia de usuario más fluida, especialmente en escenarios donde múltiples clientes realizan consultas similares de manera simultánea.

3. Propuesta de Solución

En esta sección se describe la solución propuesta para automatizar el proceso de cotización de productos mediante un chatbot con inteligencia artificial. El sistema está diseñado para ser utilizado por múltiples empresas, ofreciendo un panel administrativo web, un widget de chat embebible, integración con WhatsApp y un motor de IA que procesa las consultas de los clientes y genera cotizaciones basadas en el catálogo real de productos de cada empresa.

3.1. Descripción general

La solución consiste en un sistema de chatbot con inteligencia artificial orientado a la atención al cliente y la generación de cotizaciones de productos. El sistema permite a las empresas registradas ofrecer a sus clientes un canal de comunicación automatizado a través de WhatsApp y un widget web, desde donde pueden realizar consultas sobre productos y solicitar cotizaciones de manera automática.

El sistema cuenta con un panel administrativo web desde el cual los administradores pueden gestionar empresas, usuarios, catálogos de productos, conversaciones y reportes de uso. La inteligencia artificial integrada procesa los mensajes de los clientes, consulta la información real de los productos registrados y genera respuestas y cotizaciones congruentes con el catálogo disponible, evitando respuestas fuera de contexto.

3.2. Arquitectura general

La arquitectura del sistema se compone de los siguientes elementos:

- **Backend:** Desarrollado con Laravel, expone una API REST que centraliza la lógica de negocio, la autenticación, el control de permisos y la integración con servicios externos.
- **Frontend administrativo:** Construido con React, TypeScript, Tailwind CSS y Vite, ofrece una interfaz moderna y responsiva para la gestión del sistema.
- **Base de datos:** PostgreSQL como sistema gestor de base de datos relacional, almacenando toda la información de empresas, usuarios, productos, conversaciones, cotizaciones y auditoría.
- **Caché y colas:** Redis se utiliza para el almacenamiento en caché de consultas frecuentes

y para el manejo de colas de procesamiento asíncrono, como el envío de mensajes por WhatsApp y las llamadas a la API de IA.

- **Integración con WhatsApp:** Se utiliza WhatsApp Business Platform para la recepción y envío de mensajes automatizados.
- **Motor de IA:** Integración con OpenAI, específicamente con el modelo GPT-4o-mini, encargado de procesar las conversaciones y generar respuestas y cotizaciones basadas en el catálogo real de productos de cada empresa.
- **Widget web:** Componente embebible en JavaScript que permite a los clientes interactuar con el chatbot desde el sitio web de cada empresa.
- **Despliegue:** El sistema se despliega en un VPS de DigitalOcean con Ubuntu, Nginx, PHP 8.3+, PostgreSQL y Redis.

A continuación, en la figura 6 se presenta un diagrama de arquitectura hecho como parte de la documentación del sistema, que ilustra la interacción entre los diferentes componentes y servicios involucrados en la solución propuesta.




Figura 6: Diagrama de arquitectura del sistema propuesto.

3.3. Módulos del sistema

El sistema se organiza en los siguientes módulos funcionales:

- **Módulo de empresas:** Permite a los administradores registrar, editar, activar y desactivar empresas. Cada empresa cuenta con su propia configuración individual, incluyendo la selección del modelo de IA, las reglas del chatbot y la configuración de WhatsApp y widget.
- **Módulo de usuarios:** Gestiona los usuarios del sistema, asignándolos a una empresa específica y definiendo sus roles (administrador general, administrador de empresa o usuario de empresa) para controlar el acceso y las operaciones permitidas.
- **Módulo de productos:** Permite la gestión del catálogo de productos mediante registro manual, importación masiva desde archivos CSV e importación asistida con IA. Incluye validaciones de stock, precios, categorías y duplicados, así como la activación y desactivación de productos.
- **Módulo de chats:** Registra todas las conversaciones de los clientes, tanto desde el widget web como desde WhatsApp, almacenando el historial completo de mensajes, el canal de origen y el estado de cada conversación.
- **Módulo de cotizaciones:** Genera cotizaciones automáticas a partir de los productos seleccionados durante la conversación, calculando cantidades, precios, subtotales y totales. Las cotizaciones pueden ser guardadas, consultadas en el historial y exportadas a PDF.
- **Módulo de reportes y auditoría:** Genera reportes de uso por empresa, incluyendo tokens consumidos, conversaciones atendidas, productos consultados y cotizaciones generadas. Además, registra todas las acciones importantes del sistema para su posterior auditoría.
- **Módulo de configuración:** Permite configurar parámetros generales del sistema, como el modelo de IA, los límites de uso, la configuración del widget, la configuración de WhatsApp y las reglas del chatbot.

3.4. Tecnologías utilizadas

El sistema se desarrolla utilizando el siguiente stack tecnológico:

- **Backend:** Laravel (PHP), con Laravel Sanctum para autenticación mediante tokens, spatie/laravel-permission para el control de roles y permisos, y Laravel Excel para la exportación de reportes.
- **Frontend:** React con TypeScript, Tailwind CSS para estilos y Vite como bundler.
- **Base de datos:** PostgreSQL, aprovechando sus tipos de datos avanzados como JSON y su capacidad de búsqueda full-text.
- **Caché y colas:** Redis, utilizado para el almacenamiento en caché y el manejo de colas de procesamiento asíncrono.
- **IA:** Se utilizará el modelo GPT-4o-mini como motor de inteligencia artificial, encargado de procesar las conversaciones, interpretar las consultas de los clientes y generar respuestas y cotizaciones basadas en el catálogo real de productos de cada empresa.
- **IA:** Integración configurable con Laravel AI SDK (nativo de Laravel 13) o con servicios externos como OpenAI o modelos locales como Ollama.
- **Despliegue:** DigitalOcean (VPS) con Ubuntu, Nginx, PHP 8.3+, PostgreSQL y Redis.

3.5. Flujo de trabajo del sistema

El flujo de trabajo del sistema comienza cuando un cliente envía un mensaje a través del widget web o WhatsApp. El mensaje es recibido por el backend, que identifica la empresa correspondiente y procesa la consulta mediante el motor de IA. El motor de IA analiza el mensaje, consulta la base de datos de productos de la empresa y genera una respuesta o cotización basada en el catálogo real disponible. La respuesta se envía de vuelta al cliente a través del mismo canal y se registra la conversación en la base de datos para su posterior auditoría. Este proceso asegura que las respuestas sean precisas, rápidas y estén siempre basadas en información actualizada.

Referencias

- [1] Sheng Wang et al. “Building user trust in AI chatbots for customer service through human-like cues and perceived reliability”. En: *Scientific Reports* 16 (2026), pág. 7860.
- [2] Yi Ding y Muzammil Najaf. “Interactivity, humanness, and trust: a psychological approach to AI chatbot adoption in e-commerce”. En: *BMC Psychology* 12 (2024).
- [3] Chandran Nandkumar y Luka Peternel. “Enhancing supermarket robot interaction: an equitable multi-level LLM conversational interface for handling diverse customer intents”. En: *Frontiers in Robotics and AI* 12 (2025), pág. 1576348.
- [4] Wang Wang et al. “Smart customer service in unmanned retail store enhanced by large language model”. En: *Scientific Reports* 14 (2024).
- [5] Stuart Russell y Peter Norvig. *Artificial Intelligence: A Modern Approach*. Pearson, 2020.
- [6] Daniel Jurafsky y James H. Martin. *Speech and Language Processing*. Pearson, 2020.
- [7] Ashish Vaswani et al. “Attention is all you need”. En: *Advances in Neural Information Processing Systems* 30 (2017).
- [8] Tom Brown et al. “Language models are few-shot learners”. En: *Advances in Neural Information Processing Systems* 33 (2020), págs. 1877-1901.
- [9] Patrick Lewis et al. “Retrieval-augmented generation for knowledge-intensive nlp tasks”. En: *Advances in Neural Information Processing Systems* 33 (2020), págs. 9459-9474.
- [10] Yunfan Gao et al. “Retrieval-augmented generation for large language models: A survey”. En: *arXiv preprint arXiv:2312.10997* (2023).
- [11] Meta. *WhatsApp Business Platform API Documentation*. <https://developers.facebook.com/docs/whatsapp>. 2024.
- [12] Juan Guillermo Rivera Berrío. *Inteligencias artificiales generativas a 2023*. Córdoba, España: Fondo Editorial RED Descartes, 2023.
- [13] Joan-Francesc Fondevila-Gascón et al. “El chatbot como factor de éxito comunicativo, de marketing y empresarial: análisis empírico”. En: *Correspondencias y Análisis* 19 (2024), págs. 47-70.
- [14] Ricoh. *OHLA integra la inteligencia artificial conversacional para mejorar la eficiencia operativa y reducir el tiempo dedicado a la búsqueda de información y la toma de decisiones*. Caso de éxito. 2024. URL: <https://www.ricoh.es>.
- [15] Rafael Muñoz Guillena. *Procesamiento del lenguaje natural como eje central de la inteligencia artificial generativa*. Logroño, España: Universidad de La Rioja, Servicio de Publicaciones, 2024.

- [16] Darío Saúl Navarro. “Alucinaciones de los grandes modelos de lenguaje y la importancia del control humano en el ámbito jurídico. Recomendaciones de uso a partir del caso “Roberto Mata vs. Avianca Airlines Inc.””. En: *Revista Científica de la Facultad de Derecho y Ciencias Sociales y Políticas - UNNE* 4.2 (2025). DOI: [10.30972/rcd.428685](https://doi.org/10.30972/rcd.428685). URL: <https://doi.org/10.30972/rcd.428685>.
- [17] Wentao Hu et al. “Removal of Hallucination on Hallucination: Debate-Augmented RAG”. En: *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics*. Vienna, Austria: Association for Computational Linguistics, 2025, págs. 15839-15853.
- [18] Taoye Yin et al. “Mitigating Hallucination in Financial Retrieval-Augmented Generation via Fine-Grained Knowledge Verification”. En: *arXiv preprint arXiv:2602.05723* (2026).
- [19] Anna Neumann et al. “Position is Power: System Prompts as a Mechanism of Bias in Large Language Models”. En: *arXiv preprint* (2025).
- [20] Mahmud Omar et al. “Multi-model assurance analysis showing large language models are highly vulnerable to adversarial hallucination attacks during clinical decision support”. En: *Communications Medicine* 5 (2025), pág. 330.
- [21] Daniel Laparra Osa. “Retrieval-Augmented Generation para la Extracción de Información de Documentos Inteligente”. Trabajo Fin de Grado. Valencia, España: Universitat Politècnica de València, 2024.
- [22] Soham Mukherjee et al. *Augmenting Large Language Models with External Data Sources: A Systematic Review of Methodologies, Performance Metrics, and Information Fidelity*. Preprints. 2025. DOI: [10.20944/preprints202604.0717.v1](https://doi.org/10.20944/preprints202604.0717.v1).
- [23] IBM. “¿Qué es múltiples inquilinos?” En: (oct. de 2021). Consultado el 24 de junio de 2026.
- [24] Future Processing. “Multi-tenant architecture explained: benefits, risks and performance”. En: (oct. de 2025). Consultado el 24 de junio de 2026.
- [25] MuyComputer. “Memoria caché: qué es y qué diferencias hay entre los tipos L1, L2, L3 y L4”. En: *MuyComputer* (jul. de 2024). Consultado el 26 de junio de 2026.
- [26] Heroku Dev Center. *Understanding Heroku Postgres Data Caching*. https://devcenter-heroku-com.translate.goog/articles/understanding-postgres-data-caching?_x_tr_sl=en&_x_tr_tl=es&_x_tr_hl=es&_x_tr_pto=sge. Consultado el 26 de junio de 2026. Ene. de 2026.
- [27] William Johnston. “What is Redis?: An Overview”. En: *Redis Tutorials* (nov. de 2025). Consultado el 26 de junio de 2026.

- [28] Adaline Labs. “What is prompt caching? How can product managers leverage it to develop user-friendly products?” En: *Adaline Labs* (mar. de 2025). Consultado el 26 de junio de 2026.

Instituto Mexicano del Seguro Social

Constancia de Vigencia de Derechos

Homoclave del trámite	Homoclave del formato	Fecha de publicación del formato en el DOF
IMSS-02-020	FF-IMSS-012	10 / 11 / 2015 DD MM AAAA

Datos Generales

NSS:	26240656640
CURP:	COSA061130HTSRNNA3
Nombre(s), primer apellido y segundo apellido:	ANGEL GABRIEL CORONADO SANCHEZ
Sexo:	Hombre
Fecha de nacimiento:	30/11/2006
Lugar de nacimiento:	TAMAULIPAS

Datos de Aseguramiento

Con derecho al servicio médico:	SI
Vigente:	31/03/2026
Delegación:	TAMAULIPAS
UMF:	HGZ 001 CIUDAD VICTORIA
Turno:	VESPERTINO
Consultorio:	CONSULTORIO 17
Agregado Médico:	1M2006ES

Datos de Aseguramiento

Registro Patronal	Nombre o razón social
F0543370327	UNIVERSIDAD POLITECNICA DE VICTORIA
Modalidad de Aseguramiento	Descripción de Modalidad
MODALIDAD 32	SEGURO FACULTATIVO ESTUDIANTES

Detalle de vigencia

Estado	Inicio de Vigencia	Fecha de Constancia
VIGENTE	03/02/2026	31/03/2026


Beneficiarios

NO APLICA

"De conformidad con los artículos 4 y 69-M, fracción V de la Ley Federal de Procedimiento Administrativo, los formatos para solicitar trámites y servicios deberán publicarse en el Diario Oficial de la Federación (DOF)"

**GOBIERNO DE
MÉXICO****Contacto**

Paseo de la Reforma 476, P.B.
Col. Juárez, Alcaldía Cuauhtémoc
C.P. 06600, Ciudad de México.
Tel. 800 623 23 23
<http://www.imss.gob.mx/contacto>



Ciudad Victoria,
Tamaulipas, a 01
de Mayo
de 2026

TIKS Y CAPACITACIONES S. DE R.L.
DR. MARIO HUMBERTO RODRÍGUEZ CHÁVEZ
PRESENTE

La Universidad Politécnica de Victoria tiene a bien presentar a **CORONADO SÁNCHEZ ANGEL GABRIEL** estudiante del programa académico de **INGENIERÍA EN TECNOLOGÍAS DE LA INFORMACIÓN E INNOVACIÓN DIGITAL** en su modalidad de **DESARROLLO DE SOFTWARE MULTIPLATAFORMA**, con número de matrícula **2430124** y seguro facultativo IMSS número **26240656640**; quien deberá realizar su práctica profesional de **ESTADÍA TSU**, a partir del **04 de Mayo de 2026** al **14 de Agosto de 2026**, con duración de **600 horas** desarrollando el proyecto **"DESARROLLO E IMPLEMENTACIÓN DE UN SISTEMA COTIZADOR DE PRODUCTOS A TRAVÉS DE INTELIGENCIA ARTIFICIAL"** que le fue asignado.

Al concluir se le extenderá la carta de liberación al evaluarlo satisfactoriamente y además le solicitaremos su valiosa opinión respondiendo el formulario que se le enviará por correo electrónico, referente al desempeño del practicante, la información que nos proporcione es de vital importancia para la mejora de los programas académicos que ofrece la Universidad Politécnica de Victoria para la formación de profesionistas altamente especializados.

El practicante deberá cumplir con el Reglamento Interno aplicable al personal en su campo de trabajo.

Sin otro particular,

ATENTAMENTE

OTHÓN CANO GARZA
DIRECTOR DE VINCULACIÓN



UNIVERSIDAD POLITÉCNICA DE VICTORIA

Av. Nuevas Tecnologías 5932
Parque Científico y Tecnológico de Tamaulipas
Carretera Victoria Soto La Marina Km. 5.5
Cd. Victoria, Tamaulipas. C.P. 87138

Tel: (834) 1711100 al 10
www.upvictoria.edu.mx



Ciudad Victoria, Tamaulipas, a 8 de mayo del 2026

M.A. Othón Cano Garza
Dir. de Vinculación Empresarial
Universidad Politécnica de Victoria

PRESENTE.-

Por medio de la presente hago de su conocimiento que el alumno **CORONADO SÁNCHEZ ANGEL GABRIEL** con número de matrícula **2430124** del programa académico de **INGENIERÍA EN TECNOLOGÍAS DE LA INFORMACIÓN E INNOVACIÓN DIGITAL**, ha sido aceptado en el proyecto "**Desarrollo e implementación de un sistema cotizador en línea a través de inteligencia artificial**", a fin de realizar su Estadía. Dicho proyecto deberá cumplir un total de 600 horas, durante el periodo comprendido **del 04 de mayo al 14 de agosto del 2026**.

Esperando que la presente sea de utilidad al interesado, agradezco su atención.

ATENTAMENTE


Dr. Mario Humberto Rodríguez Chávez
Titular de desarrollo de software



Rúbrica para la Evaluación del Reporte de Estadía

Nombre completo del estudiante: Angel Gabriel Coronado Sánchez Matrícula: 2430124 PERIODO: Mayo-Agosto 2026 Nombre del evaluador: Dr. Said Polanco Martagón			
Firma del Evaluador: _____ Calificación Final: ____ / 100			
Valor	Características a cumplir	Puntos	Observaciones
6	Resumen ejecutivo y abstract: Indica qué se realizó, cómo se realizó y qué se obtuvo. (una cuartilla en español e inglés)		
6	Contenido temático: Describe correctamente el contenido del documento		
6	Introducción: El informe cumple con introducir al lector de una manera atractiva el panorama general del trabajo realizado en la unidad económica.		
6	Descripción de la unidad económica: Se redactan los detalles de los antecedentes del departamento, la empresa, giro, misión, visión, infraestructura, ubicación.		
6	Objetivos operativos: Describen las acciones a cumplir mediante actividades establecidas por el asesor empresarial		
24	Metodología: Descripción a detalle de las etapas y procedimientos utilizados en el proyecto		
18	Resultados: Interpreta y analiza los resultados obtenidos durante su estadía.		
12	Conclusiones: Las conclusiones son claras y acordes con el objetivo esperado		
6	Bibliografía y anexos: Cita correctamente las fuentes de información utilizando un estilo de referencia; anexa cartas correspondientes		
10	Responsabilidad: Entregó el reporte en la fecha y hora señalada. Asistió al menos al 80 % de sus días de Estadía		

Rúbrica para Exposición del Reporte de Estadía

Criterio	Nivel de logro		
	Bueno (10 %)	Regular (7 %)	Menor a lo esperado (5 %)
Dominio del tema (10 %)	Utiliza todos los términos y conceptos de manera correcta.	Utiliza la mayoría términos y conceptos de manera correcta	Confunde los términos y conceptos.
Presentación de material visual (10 %)	Las diapositivas usadas tienen fondo claro, letras, tablas e imágenes visibles. La presentación contiene los aspectos relevantes de la Estadía	Las diapositivas usadas presentan dificultad para su apreciación visual. La presentación contiene los aspectos relevantes de la Estadía	Las diapositivas usadas presentan dificultad para su apreciación visual. La presentación carece de algunos aspectos relevantes de la Estadía.
Comunicación y expresión (10 %)	Su volumen de voz es comprensible. Su expresión corporal manifiesta seguridad ejecutiva. Su atuendo cumple los estándares de ser formal o semiformal. Mantiene una línea de respeto en general.	Su volumen de voz no es comprensible. Su expresión corporal manifiesta inseguridad. Su atuendo cumple los estándares de ser formal o semiformal. Mantiene una línea de respeto en general.	Su volumen de voz no es comprensible. Su expresión corporal manifiesta inseguridad. Su atuendo no cumple los estándares de ser formal o semiformal. Realiza alguna falta de respeto.
Respuestas (10 %)	Las respuestas son consistentes y con parámetros de lógica operativa.	Las respuestas no son consistentes pero tienen parámetros de lógica operativa.	Las respuestas son difusas e incoherentes.
Ponderación final de su exposición:		___ /100	
Día / Mes / Año		12/ Agosto/ 2026	
Comentario adicional			